



Universidad Nacional Autónoma de  
México

FACULTAD DE CIENCIAS

ALGORITMO DE  
SEGMENTACION SLIC  
MEJORADO

*Procesamiento digital de imagenes*

Autor:  
Raúl Labonne Arizmendi

1 de Junio de 2026

# Chapter 1

## Introducción

### 1.1 Datos de entrada:

Para los datos de entrada consideramos 10 imágenes de células en escala de grises de resolución 512x512 en formato **PNG** dadas por la base de datos [3], siendo las siguientes:




Figure 1.1: Conjunto de las 10 imágenes celulares en escala de grises utilizadas como datos de prueba inicial.

También debemos considerar un número  $nsp$  el cual servirá para poder determinar el número de superpíxeles en los que queremos segmentar la imagen.

Para esta ocasión utilizaremos 750 superpíxeles, es decir,  $nsp = 750$ .

### 1.2 Preprocesamiento

Para mejorar la segmentación mediante el algoritmo SLIC (*Simple Linear Iterative Clustering*) modificado, se aplica un método de preprocesamiento avanzado a las imágenes celulares microscópicas [1]. Este procedimiento consiste en un

realce de contraste no lineal y una ecualización regional en escala de grises. El objetivo principal es intensificar los bordes débiles de las membranas celulares (volviéndolos muy oscuros o muy brillantes en comparación con el fondo) y homogeneizar las regiones de interés. Para lograr esto, el algoritmo implementa una técnica de ecualización de histograma regional dividida en dos etapas principales:

### 1.2.1 División de la imagen mediante el criterio de máxima entropía

En primer lugar, la imagen microscópica original en color se transforma de manera no lineal a una imagen en escala de grises con  $n$  niveles de gris. Posteriormente, el histograma de la imagen se divide aleatoriamente en  $K$  segmentos.[1]

Asumiendo que la distribución de probabilidad de cada nivel de gris está representada por  $p_i$  (para  $i = 0, 1, \dots, n - 1$ ), y que los múltiples umbrales óptimos de clasificación para cada segmento se denotan como  $\{t_1, t_2, \dots, t_K\}$ , la entropía total basada en estos segmentos se expresa matemáticamente como:

$$H(t_1, t_2, \dots, t_K) = \sum_{j=1}^{K+1} H_j \quad (1.1)$$

Los múltiples umbrales óptimos  $\{t_1^*, t_2^*, \dots, t_K^*\}$  para la clasificación de cada segmento satisfacen el criterio de máxima entropía, el cual se define mediante la siguiente expresión:

$$\{t_1^*, t_2^*, \dots, t_K^*\} = \arg \max \{H(t_1, t_2, \dots, t_K)\} \quad (1.2)$$

La solución óptima de este sistema de múltiples umbrales se calcula de manera eficiente en el sistema mediante la implementación de un algoritmo de iteración condicional.[1]

### 1.2.2 Ecualización regional y transformación de escala de grises

Una vez obtenidos los umbrales óptimos del paso anterior, la escala de grises de la imagen queda segmentada en  $K + 1$  partes. Sea  $[X_i, X_{i+1}]$  un intervalo de niveles de gris observado, este es transformado a un nuevo intervalo  $[Y_i, Y_{i+1}]$  mediante una función de transformación monótona  $f(x)$ , logrando así un efecto de mejora de contraste local y ecualización regional.

La función  $f(x)$  posee un comportamiento no lineal: es una función convexa en el subintervalo  $[X_i, X_m]$  y una función cóncava en el subintervalo  $[X_m, X_{i+1}]$ . El punto de inflexión es  $(X_m, Y_m)$ , donde  $Y_m = (Y_i + Y_{i+1})/2$ , y el valor de  $X_m$  se calcula de acuerdo con el principio de mínimos cuadrados mediante la siguiente relación:

$$X_m = \frac{\int_{X_i}^{X_{i+1}} xp(x)dx}{\int_{X_i}^{X_{i+1}} p(x)dx} \quad (1.3)$$

Para reducir la complejidad computacional de la transformación de la escala de grises de la imagen,  $f(x)$  se establece como una función analítica continua con la siguiente forma:

$$f(x) = ax^r + b, \quad x \geq 1, \quad r \geq 1 \quad (1.4)$$

donde los coeficientes  $a$  y  $b$  están dados por:

$$a = \frac{Y_{i+1} - Y_i}{X_{i+1}^r - X_i^r}, \quad b = Y_i - aX_i^r \quad (1.5)$$

Al modificar el valor del parámetro  $r$ , se puede obtener una familia de curvas de transformación. A mayor valor de  $r$ , mayor será el grado de ecualización de gris en el intervalo transformado  $[X_i, X_{i+1}]$ . Seleccionando adecuadamente  $Y_i$  y el parámetro  $r$  para transformar la escala de grises de cada intervalo, se pueden obtener imágenes regionalmente equilibradas y con un contraste mejorado, lo cual es ideal para la posterior aplicación del algoritmo SLIC.[1]

## Chapter 2

# SLIC base

Para comprender el algoritmo SLIC modificado, es necesario explicar primero el funcionamiento del método original. Esto permitirá destacar los cambios más significativos entre ambas versiones[2].

### 2.1 Inicialización

- Definimos un valor  $S$  que determina el tamaño de cada superpíxel, el cual se obtiene mediante la siguiente fórmula:

$$S = \sqrt{\frac{nt}{nsp}}$$

Donde  $nsp$  es el parámetro recibido (número de superpíxeles) y  $nt$  es el número total de píxeles que componen la imagen.

- Definimos un centro o media  $m_i$  para el superpíxel  $i$  dentro de una región de tamaño  $2S \times 2S$ , el cual se ubica inicialmente en el centro topológico del superpíxel.
- Desplazamos este centroide dentro de una vecindad de  $3 \times 3$  alrededor de la media  $m_i$  hacia la posición que presente el menor valor en la magnitud del gradiente. (Para obtener los gradientes, es posible utilizar el filtro de Sobel).
- Se inicializan dos imágenes adicionales con las mismas dimensiones que la original:

- Imagen de etiquetas  $L(p) = -1$
- Imagen de distancias  $d(p) = \infty$

Para el resto del algoritmo, cada píxel  $p$  de la imagen se considera como un vector de 5 dimensiones. Dependiendo de si se utiliza un espacio de color RGB o LAB, el vector se define como:

- $z_p = [r, g, b, x, y]$  o  $z_p = [l, a, b, x, y]$ , donde  $r, g, b$  corresponden a los canales RGB y  $l, a, b$  a los canales LAB.

Para el cálculo de las distancias entre dos vectores  $z_i$  y  $z_j$ , utilizamos el siguiente sistema de ecuaciones:

$$\begin{aligned} d_s(z_i, z_j) &= \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2} \\ d_c(z_i, z_j) &= \sqrt{(r_i - r_j)^2 + (g_i - g_j)^2 + (b_i - b_j)^2} \\ D(u, v) &= \sqrt{\left(\frac{d_c(u, v)}{c}\right)^2 + \left(\frac{d_s(u, v)}{S}\right)^2} \end{aligned} \quad (2.1)$$

Donde  $d_s$  es la distancia espacial,  $d_c$  es la distancia de color (en este caso ilustrada para RGB, pero adaptable de forma análoga a LAB) y  $D$  es la distancia total entre los vectores  $u$  y  $v$ .

## 2.2 Algoritmo

El algoritmo consta de los siguientes tres pasos principales y una etapa adicional de postprocesamiento:

1. Para cada píxel  $z_p$  dentro de la región de búsqueda de un superpíxel  $S$ , calculamos su distancia respecto a la media  $m_i$ .  
Si esta distancia es menor que el valor actual almacenado en  $d(p)$ , actualizamos  $d(p)$  con la nueva distancia y asignamos a la etiqueta  $L(p)$  el índice  $i$ . Este proceso se repite para todos los píxeles en la vecindad de cada superpíxel.
2. Una vez completado el paso anterior, actualizamos la media  $m_i$  de cada superpíxel  $S_i$  utilizando la siguiente expresión:

$$m_i = \frac{1}{|C_i|} \sum_{z \in C_i} z \quad (2.2)$$

Donde el conjunto  $C_i = \{z_p \mid L(p) = i \ \forall p\}$  contiene todos los píxeles asignados al superpíxel  $i$ .

3. Verificamos la convergencia calculando la suma de las diferencias (en norma  $L_2$ ) entre los centros  $m_i$  actualizados y sus posiciones anteriores. Si esta diferencia es menor a un umbral  $\tau > 0$ , el algoritmo termina; de lo contrario, se repite desde el paso 1.

Durante el postprocesamiento, construimos una imagen segmentada de salida  $I'(p)$  definida como:

$$I'(p) = m_{L(p)} \quad \forall p = 1, 2, \dots, nt \quad (2.3)$$

Esto asigna a cada píxel el valor de intensidad o color promedio del superpíxel al que pertenece.

## 2.3 Resultados de SLIC

Primero aplicamos este algoritmo base para evidenciar las limitaciones que presenta SLIC frente a imágenes celulares. Los resultados obtenidos se muestran a continuación:




Figure 2.1: Segmentación delineada por bordes utilizando el algoritmo SLIC base y la máscara resultante tras aplicar K-medias con  $k = 2$ .

Como se puede observar, las máscaras presentan una notable pérdida de detalle en los bordes de las células, otorgándoles un aspecto pixelado. Esto

ocurre porque el algoritmo SLIC base es muy sensible a las características de este tipo de imágenes biomédicas: si se elige un número bajo de superpíxeles, se pierde resolución en el contorno celular; por el contrario, si se incrementa este parámetro, se corre el riesgo de generar una sobresegmentación severa de la imagen.



## Chapter 3

# SLIC Mejorado (ISLIC)

### 3.1 Cambios realizados

El enfoque principal de este método radica en proponer una variante del algoritmo SLIC adaptada específicamente para imágenes celulares, lo que permite ajustarse mejor a su morfología y evitar la pérdida de detalles importantes.

A continuación, se detallan las modificaciones más relevantes respecto al algoritmo original:

#### 3.1.1 Entrada

Si bien desde un inicio definimos nuestra entrada como una imagen en escala de grises, este fue uno de los aportes principales del artículo, ya que el algoritmo SLIC original operaba con tres canales de información (como RGB o LAB). Con este cambio, únicamente se procesa un canal correspondiente al valor de intensidad.

#### 3.1.2 Vector de 3 dimensiones

Al reducir la imagen de tres canales a un solo canal, deja de ser necesario expresar cada píxel  $p$  como un vector de 5 dimensiones. Por lo tanto, los nuevos vectores serán de 3 dimensiones y se representan de la siguiente manera:

- $z_p = [g, x, y]$  donde  $g$  es el canal de la escala de grises.

#### 3.1.3 Distancia

La única modificación respecto a la métrica original radica en la forma en que se calcula la distancia de color. Al contar con un solo canal, la fórmula se simplifica a la siguiente ecuación:

$$d_c(z_i, z_j) = \sqrt{(g_i - g_j)^2} \quad (3.1)$$

El resto de la ecuación de distancia total permanece sin cambios.

### 3.1.4 Superpíxeles circulares

El cambio más importante propuesto es la geometría con la que se define cada superpíxel. En el método SLIC original se consideran regiones cuadradas de  $2S \times 2S$ , lo cual es una de las principales causas de la pérdida de detalles en los contornos de la célula.

Para solucionar esto, en lugar de usar cuadrados, se emplea una región circular de radio  $S$ .

Por lo tanto, el único cambio adicional en el algoritmo se aplica en el primer paso, agregando la siguiente condición:

- Sean  $cx$  y  $cy$  las coordenadas de la media  $m$ , y  $x, y$  las coordenadas del píxel  $z_i$ . Si  $(x - cx)^2 + (y - cy)^2 > S^2$ , el píxel se ignora y se continúa iterando sobre los demás píxeles del superpíxel  $S$ .

## 3.2 Resultados de ISLIC

Podemos ver de mejor forma como es que la mascara resultante se asemeja bastante a la forma original de la celula, adaptandose de mejor forma a las formas circulares de las mismas a comparación del algoritmo base Slic.




Figure 3.1: Segmentación delineada por bordes utilizando el algoritmo SLIC modificado (ISLIC) y la máscara resultante tras aplicar K-medias con  $k = 2$ .

## Chapter 4

# Resultados Finales

La evaluación del método propuesto se realizó utilizando la base de datos de [3], la cual proporciona las imágenes originales junto con sus respectivas máscaras de referencia. Para cuantificar el rendimiento y la exactitud de nuestra segmentación, se emplearon los coeficientes DICE e IoU (Intersección sobre Unión). Ambas métricas se evalúan en un rango de 0 a 1, donde 0 indica una ausencia total de superposición (error crítico) y 1 representa una segmentación perfecta. Los resultados cuantitativos obtenidos se presentan a continuación:

Table 4.1: Resultados del coeficiente DICE

| Imagen          | ISLIC  | SLIC base |
|-----------------|--------|-----------|
| 0               | 0.7065 | 0.7016    |
| 1               | 0.9096 | 0.8806    |
| 2               | 0.8929 | 0.8812    |
| 3               | 0.9678 | 0.9300    |
| 4               | 0.9489 | 0.9638    |
| 5               | 0.9319 | 0.9045    |
| 6               | 0.9276 | 0.9353    |
| 7               | 0.9220 | 0.9247    |
| 8               | 0.9324 | 0.8928    |
| 9               | 0.8911 | 0.9089    |
| <b>Promedio</b> | 0.9031 | 0.8923    |

Table 4.2: Resultados del coeficiente IoU

| Imagen          | ISLIC  | SLIC base |
|-----------------|--------|-----------|
| 0               | 0.5461 | 0.5403    |
| 1               | 0.8341 | 0.7867    |
| 2               | 0.8066 | 0.7876    |
| 3               | 0.9376 | 0.8691    |
| 4               | 0.9028 | 0.9301    |
| 5               | 0.8726 | 0.8257    |
| 6               | 0.8650 | 0.8785    |
| 7               | 0.8553 | 0.8599    |
| 8               | 0.8733 | 0.8063    |
| 9               | 0.8035 | 0.8330    |
| <b>Promedio</b> | 0.8297 | 0.8117    |

Como se puede observar en las métricas anteriores, el algoritmo modificado (ISLIC) supera consistentemente al SLIC original, logrando promedios globales más altos tanto en el coeficiente DICE (0.9031 frente a 0.8923) como en la métrica IoU (0.8297 frente a 0.8117). Más allá de esta mejora cuantitativa, es importante destacar un aspecto cualitativo crucial: aunque el método SLIC base alcanza métricas competitivas, sus resultados visuales presentan deficien-

cias notables, tales como la pérdida de resolución espacial y la incapacidad de preservar de manera óptima los contornos finos de la célula. Estas limitaciones son mitigadas con éxito mediante la implementación de ISLIC.

## Chapter 5

# Conclusión

En este proyecto se abordó el desafío de la segmentación de imágenes celulares, un proceso fundamental en el análisis de imágenes biomédicas. Durante la evaluación inicial, se demostró que el algoritmo SLIC original, aunque es un estándar eficiente para imágenes de propósito general, presenta limitaciones significativas al aplicarse en el dominio celular. El uso de canales de color múltiples y vecindades de búsqueda cuadradas provoca que las segmentaciones pierdan resolución en los contornos, generando máscaras con aspecto pixelado y obligando a un compromiso difícil entre la pérdida de detalle y la sobresegmentación.

Para mitigar estas deficiencias, se implementó y evaluó el algoritmo ISLIC (SLIC modificado). Esta variante adaptó el método a la naturaleza de las imágenes celulares mediante tres cambios clave: la transición a un espacio de un solo canal (escala de grises), la reducción del vector de características a tres dimensiones, y, de manera crucial, la modificación geométrica de los superpíxeles de un área cuadrada a una región circular de radio  $S$ . Este último cambio resultó determinante para adaptarse de forma natural a la morfología curva inherente a las células.

La validación experimental, realizada sobre un conjunto de datos estandarizado y comparada contra máscaras de referencia, confirmó la superioridad del método propuesto. Cuantitativamente, ISLIC logró promedios superiores tanto en el coeficiente DICE (0.9031 frente a 0.8923 del método base) como en la métrica IoU (0.8297 frente a 0.8117). Más allá de los números, la mejora cualitativa fue notable: el método modificado logró preservar de manera mucho más fiel y suave los bordes celulares.

En conclusión, la adaptación de las características espaciales y de intensidad en el algoritmo ISLIC demuestra ser una solución robusta y eficaz. Los resultados obtenidos confirman que considerar la morfología del objeto de estudio en el diseño de los superpíxeles no solo mejora la exactitud matemática de la segmentación, sino que produce representaciones visuales mucho más útiles y precisas para el análisis biomédico.

# Bibliography

- [1] F. He, M. Parvez Mahmud, A. Z. Kouzani, A. Anwar, F. Jiang, and S. H. Ling, “An improved slic algorithm for segmentation of microscopic cell images,” *Biomedical Signal Processing and Control*, vol. 73, p. 103464, 2022, ISSN: 1746-8094. DOI: <https://doi.org/10.1016/j.bspc.2021.103464>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1746809421010612>.
- [2] R. Achanta, A. Shaji, K. Smith, A. Lucchi, P. Fua, and S. Süsstrunk, “Slic superpixels compared to state-of-the-art superpixel methods,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 34, no. 11, pp. 2274–2282, 2012. DOI: 10.1109/TPAMI.2012.120.
- [3] M. Aydin and Z. Kuş, “Medsegbench: A comprehensive benchmark for medical image segmentation in diverse data modalities,” *Scientific Data*, vol. 11, no. 1, p. 1283, 2024. DOI: 10.1038/s41597-024-04159-2. [Online]. Available: <https://doi.org/10.1038/s41597-024-04159-2>.